

Modulo 9 - Introducción al Aprendizaje Profundo

Reto 2: Predicción de personalidad aparente usando aprendizaje profundo y datos multimodales.

Importante: El Reto 2 será evaluado a través de las siguientes preguntas. **Responda de manera clara y concisa**, basándose en los resultados obtenidos al ejecutar los archivos de *Jupyter notebook* proporcionados. **Cuando haya terminado, guarde el archivo como “Nombre-Apellido_Reto_2_M09.pdf” y súbalo a través del campus virtual.** El reto se realiza en grupos. Sin embargo, cada estudiante debe subir su propio archivo en el campus virtual.

Miembros del grupo: Lluís Baldirà Jorro, Maria Barraza Diaz, Ana Gabriela Dos Santos Figueira y Max Comerma i Martos - Grup L R2

Pregunta 1: **Notebook 1 y 2** - (puntuación 0.5)

¿Qué es un “token” en la representación de características de texto (“*embedding*”) ? Explique brevemente los posibles diseños de preprocesamiento y arquitectura para procesar datos textuales.

Respuesta: Un token en la representación de características de texto es la unidad mínima de información en la que se divide un texto, y puede ser una palabra, subpalabra o carácter. La tokenización es un paso crucial en el procesamiento del lenguaje natural, ya que convierte el texto en una secuencia de tokens que luego se transforman en vectores numéricos mediante codificaciones como one-hot o embeddings (por ejemplo, Word2Vec o BERT). Estos métodos permiten capturar relaciones semánticas y reducir la dimensionalidad de la representación numérica.

En el preprocesamiento del texto, además de la tokenización, se realiza la conversión de símbolos a números (representación one-shot) y la reducción de dimensionalidad y codificación semántica (Word2vec que convierte los one-hot a una codificación más compacta imbuida con semánticas o BERT, que considera frases enteras, luego, semánticas más globales).

Para procesar datos textuales, se pueden usar distintas arquitecturas: las redes recurrentes (RNN, LSTM) que manejan secuencias en orden, o los Transformers, que emplean mecanismos de atención para procesar el texto en paralelo y capturar relaciones contextuales más complejas.

A nivel de tareas del preprocesamiento encontramos la clasificación de textos, la traducción, el resumen de textos, la extracción de palabras clave, pregunta-respuesta y diálogo.

Pregunta 2: Notebook 2 - (puntuación 1.5)

Completa la siguiente tabla con los resultados obtenidos para los modelos especificados. Luego, discute brevemente los principales hallazgos. Por ejemplo, ¿qué método obtuvo los mejores resultados y qué podría explicar eso? ¿Has observado alguna ventaja o desventaja (por ejemplo, en términos de precisión o tiempo de procesamiento)?

Modelo	MAE*
"solo texto", Secuencial (LSTM) "is_sequential = True"	0.13519
"solo texto", promedio "is_sequential = False"	0.15296

* MAE obtenido en el conjunto de prueba.

Respuesta: Observamos que el error es ligeramente mayor en el modelo que **no** tiene en cuenta la secuencia de los datos, y no aprende sobre los patrones temporales. En cambio, el primer modelo, que sí reconoce la secuencia de los datos, muestra un error menor al aprender patrones temporales y procesar los datos como una secuencia. Al utilizar el modelo secuencial, se tienen en cuenta las relaciones temporales entre los inputs, lo que permite un entrenamiento más completo. Por el contrario, cuando el modelo se especifica como no secuencial, los datos se tratan de forma independiente respecto a su orden. La diferencia en el MAE sugiere que al tener en cuenta la secuencia, el modelo capta mejor las dinámicas temporales y permite hacer predicciones más precisas al reducir el error.

Ahora bien en términos de tiempo de procesamiento el modelo que no considera la secuencia, tomaría menos tiempo de entrenar, ya que el modelo no tendría que considerar como los datos se relacionan entre ellos a través de la secuencia si no evaluar cada input de manera independiente. El considerar la secuencia implica más memoria y recursos computacionales para procesar cada input y aprender de sus dependencias temporales, lo que resulta en un modelo que toma más tiempo de entrenar.

Pregunta 3: Notebook 3 - (puntuación 0.5)

Menciona tres operaciones del modelo creado cuya salida no dependa del orden de las imágenes de entrada.

Respuesta: MaxPooling, AveragePooling y BatchNormalization.

Pregunta 4: Notebook 3 - (puntuación 2.0)

Entrena y evalúa la red con 1, 2, 3 y 4 imágenes. Luego, completa la siguiente tabla con los resultados obtenidos y comenta brevemente los principales hallazgos. Por ejemplo, ¿qué

método dio mejores resultados y qué podría explicar eso? ¿Has observado alguna ventaja o desventaja en cuanto a precisión y tiempo de procesamiento?

Modelo	n_frames	MAE*
"solo imagen"	1	0.15969
"solo imagen"	2	0.15810
"solo imagen"	3	0.15327
"solo imagen"	4	0.15291

* MAE obtenido en el conjunto de prueba.

Respuesta: Observamos que el MAE, se va reduciendo muy ligeramente conforme añadimos más frames. La diferencia entre 1 frame y 4 es de 0,00678 que es prácticamente nada significativo, sin embargo, si se muestra una tendencia a la mejora del modelo al incluir más información visual (frames), aunque concluimos que agregar más imágenes no tiene un impacto considerable en la predicción de rasgos de personalidad.

Una posible explicación para esta falta de mejora podría ser la propia base de datos que estamos analizando, debido a que se trata de videos cortos, de personas hablando enfrente de la cámara, es posible que no haya diferencias significativas entre los diferentes instantes de los videos, esto significa que la inclusión de nuevos frames no ofrece información nueva o diversa respecto al primer frame. Aun así, tomar varios frames del video en diferentes partes, puede ser útil en ciertos casos, especialmente si hay alguna variación dentro del clip, pero no parece ser el caso para la mayoría de videos en el subconjunto de First Impressions.

En cuanto al tiempo de procesamiento, observamos que conforme se van añadiendo más número de frames al modelo, más recursos son necesarios y más tiempo es dedicado para la ejecución del código, El entrenamiento con un frame tardó aproximadamente 25 minutos mientras que con 4 se demoró hasta los 50 minutos. Por lo tanto, aumentando de manera significativa y notable el tiempo dedicado para una mejora muy ligera e incluso poco significativa.

Pregunta 5: **Notebook 3** - (puntuación 1.0)

Reemplace "**GlobalAveragePooling1D**" por "**GlobalMaxPooling1D**", entrene y evalúe la red con 1 imagen. Luego, complete la siguiente tabla con los resultados obtenidos y discuta los hallazgos principales. Es decir, ¿qué método dio mejores resultados y qué podría explicar eso? ¿Has observado alguna ventaja o desventaja?

Modelo	Pooling	MAE*
"solo imagen" n_frames = 1	GlobalAveragePooling1D	0.15489
"solo imagen" n_frames = 1	GlobalMaxPooling1D	0.17343

* MAE obtenido en el conjunto de prueba.

Respuesta: Al reemplazar GlobalAveragePooling1D por GlobalMaxPooling1D, se obtuvo un Mean Absolute Error (MAE) de 0.15489 para GlobalAveragePooling1D y 0.17343 para

GlobalMaxPooling1D. Esto indica que GlobalAveragePooling1D proporcionó mejores resultados en términos de menor error. Este rendimiento superior puede explicarse por el hecho de que la operación de promedio en GlobalAveragePooling1D captura una representación más completa de las características aprendidas, lo que resulta útil para generalizar patrones en los datos. Por el contrario, GlobalMaxPooling1D, al centrarse en los valores máximos, puede perder información valiosa y ser más sensible a valores extremos.

Pregunta 6: **Notebook 3** - (puntuación 1.0)

Mantenga “**GlobalAveragePooling1D**” en el modelo pero elimine la activación “**Sigmoid**” de la última capa densa, es decir, cámbiela a “**predictions = Dense(5, activation=None) (x)**”. Luego, entrene y evalúe la red usando 1 imagen, compare los resultados (con y sin la activación *Sigmoid*) y discuta los hallazgos principales. Es decir, ¿qué método dio mejores resultados y qué podría explicar eso? ¿Has observado alguna ventaja o desventaja?

Modelo	Pooling	Activation	MAE*
“solo imagen” n_frames = 1	GlobalAveragePooling1D	Sigmoid	0.15489
“solo imagen” n_frames = 1	GlobalAveragePooling1D	None	0.57747

* MAE obtenido en el conjunto de prueba.

Respuesta: Al mantener GlobalAveragePooling1D y eliminar la activación Sigmoid en la última capa densa, el Mean Absolute Error (MAE) pasó de 0.15489 con Sigmoid a 0.57747 sin ella. Esto sugiere que la activación Sigmoid es mejor, ya que convierte las salidas en probabilidades, lo que mejora significativamente la precisión del modelo. Sin la activación, las predicciones no están acotadas, lo que resulta en un error mayor.

Pregunta 7: **Notebook 4** - (puntuación 0.5)

¿Cuál es la capa de fusión en el modelo multimodal?

Respuesta:

La capa de fusión en el modelo multimodal es la capa de “Concatenate”. Esta capa se utiliza para combinar las características extraídas tanto de las imágenes como del texto. En este caso, las características de la rama de imagen (después de procesarse con ResNet50 y las proyecciones) y las características textuales (después de ser procesadas por LSTM y proyectadas) se fusionan mediante esta capa de concatenación antes de pasar a las capas densas finales para la predicción de la personalidad aparente. Al revisar el Notebook 4, la capa de fusión es esta:

concatenate	input:	[(None, 512), (None, 512)]
Concatenate	output:	(None, 1024)

Pregunta 8: Notebook 4 - (puntuación 2.0)

Entrena y evalúa la red multimodal con 1 imagen. Luego, completa la siguiente tabla y discute los principales hallazgos. Es decir, ¿mejoró la información multimodal los resultados en comparación con los otros modelos de la tabla? ¿Qué podría explicar eso? ¿Has observado alguna ventaja o desventaja?

Modelo	MAE*
"solo texto", Secuencial (LSTM) "is_sequential = True"	0.13519
"solo texto", promedio "is_sequential = False"	0.13370
"solo imagen" n_frames = 1	0.15969
"solo imagen" n_frames = 4	0.15291
Multimodal (n_frames = 1, is_sequential = True)	0.11370

* MAE obtenido en el conjunto de prueba.

Respuesta:

En la evaluación de la red multimodal con 1 imagen, se ha observado que el modelo multimodal (n_frames = 1, is_sequential = True) ha obtenido un MAE de **0.11370**, lo cual es el valor más bajo comparado con los demás modelos evaluados. Esto sugiere que la combinación de información textual y visual mejora significativamente los resultados respecto a los modelos que solo utilizan una modalidad de datos (texto o imagen).

Aunque el modelo que utiliza solo imágenes mejora al aumentar el número de imágenes de 1 a 4, su desempeño sigue siendo inferior al de los modelos basados en texto y multimodales. Esto sugiere que la información visual por sí sola puede no ser suficiente para capturar todas las características necesarias para predecir la personalidad aparente, especialmente en casos donde la información textual proporciona contexto importante.

La ventaja principal del modelo multimodal es que combina la capacidad de la red para extraer características del texto (a través del LSTM) con la capacidad de extraer patrones visuales de las imágenes (a través de la ResNet), lo que reduce el error absoluto medio, aún así, su mayor complejidad implica una necesidad de mayores recursos computacionales y mayor capacidad de procesamiento, lo que podría ser una limitación en entornos con restricciones de hardware.

Pregunta 9: Notebook 4 - (puntuación 1.0)

En las capas "**project_embeddings**" (tanto para la imagen como para las características textuales), aumente "num_projection_layers" a 2 de la siguiente manera.

de:

```
x1 = project_embeddings(x, 1, 512, 0.3)
x2 = project_embeddings(x, 1, 512, 0.3)
```

a:

```
x1 = project_embeddings(x, 2, 512, 0.3)
x2 = project_embeddings(x, 2, 512, 0.3)
```

Luego, entrena el modelo y completa la siguiente tabla con los resultados obtenidos, y discute los hallazgos principales. Es decir, ¿qué método dio mejores resultados y qué podría explicar eso? ¿Has observado alguna ventaja o desventaja?

Modelo	num_projection_layers	MAE*
Multimodal (n_frames = 1, is_sequential = True)	1	0.11370
Multimodal (n_frames = 1, is_sequential = True)	2	0.11276

* MAE obtenido en el conjunto de prueba.

Respuesta: El segundo modelo, es decir el que añade una capa de proyección, resulta en un MAE ligeramente menor al compararse con el primer modelo. Esto se podría explicar al que al pasar por una segunda capa, el modelo es capaz de captar relaciones más complejas entre los datos, mejorando su rendimiento. Un modelo más robusto podría representar un método que puede aprender mejor y por lo tanto tener mejores resultados.

Sin embargo, hay que considerar que esto tiene un costo computacional más grande, lo que se vería reflejado en mayor tiempos de entrenamiento así como mayor uso de recursos. Por otro lado, la mayor capacidad de modelo, podría resultar en un modelo sobre ajustado, dependiendo de la muestra de datos de entrenamiento, al que le resulte más complicado mantener generalizaciones. Por lo que el añadir una segunda capa, tendrá una efectividad que dependerá de las características del conjunto de datos.